

《云计算与大数据处理》
实验报告

实验名称	实验一　云端数据接口与可复现环境
实验日期	2026 年 10 月 21 日
专业	计算机科学与技术
班级	24 计科 4
学号	2410311411
姓名	何嘉欣
指导教师	刘锦行

实验一　云端数据接口与可复现环境

一、实验目的

本实验使用本机 Moto 提供的 S3 HTTP 模拟服务，完成合成服务事件数据的“生成—保存—上传—下载—哈希核对”链路，重点区分三个层次：网络请求是否成功、上传与下载的文件内容是否逐字节一致、文件中的业务数据是否满足质量规则。

通过个人对象键改动和 payload 改动，理解对象键与内容摘要之间的关系，并通过无效 endpoint 的故障与恢复，区分连接问题、数据问题和业务问题。

二、实验环境

项目	实测值
操作系统	Windows 11
Python	3.12.13
项目解释器	D:\云计算与大数据处理\reference-BDP\.venv\Scripts\python.exe
工作目录	D:\云计算与大数据处理\reference-BDP
DuckDB / PyArrow	1.5.5 / 25.0.1
Dask / distributed	2026.8.0 / 2026.8.0
Moto / boto3	5.2.3 / 1.43.93
FastAPI	0.141.1
依赖检查	pip check：No broken requirements found.，退出码 0

环境运行证据：run_id = 8a813bc368a34c959cca8a326e937ab4，stage 为 environment。原始数据共 20,102 行、3,892,184 字节。



图 1　实验环境与原始数据检查（学号、实验号、run_id 与结果同屏）

三、实验原理与数据

3.1 对象存储与文件系统的区别

对象存储按“桶 + 对象键”定位完整对象。对象键中即使包含“/”，也只是键名的一部分，不等同于传统文件系统的目录，也不支持只修改对象中的某一行。本实验通过 boto3 的 put_object() 和 get_object() 完成真实 HTTP 往返。

固定随机种子生成合成事件

→ 保存到 data/raw/events.jsonl

→ 通过 S3 API 上传到 Moto

→ 从 Moto 下载到 outputs/lab01/downloaded-events.jsonl

→ 比较原始文件与下载文件的 SHA-256

3.2 原始数据组成

data/raw/events.jsonl 是 JSONL 文件，每行是一条 JSON 事件，主要包括 event_id、event_time、service、model、input_tokens、output_tokens、latency_ms 和 status 字段。

类别	行数
合法且 event_id 唯一	20,000
重复事件	100
非法事件	2
原始总行数	20,102

第一行样例：

```
{"event_id": "evt-00000000", "event_time": "2026-03-01T00:00:00+00:00", "service": "assistant",
 "model": "small", "input_tokens": 1538, "output_tokens": 291, "latency_ms": 1083, "status": "error"}
```

原始文件 SHA-256 为：0d93bcd25e28047f804238c220bdb5b1d2dadf328647c07de85ba0104e8e2854。本实验只验证文件经过对象接口后字节是否一致，不负责清洗重复行和非法行；这些问题留给实验 02 的质量契约处理。

四、运行前预测

预测	运行前理由	实测结果	结论
同一内容换对象键后 SHA-256 不变	SHA-256 计算对象内容字节,对象键不参与摘要计算	基线与含学号键均为 23c0…f0e8	预测正确
上传成功不代表 input_tokens=-1 合法	上传接口只负责传输字节,不负责业务字段范围校验	存在非法事件但仍上传、下载成功	预测正确
修改 payload 数值会改变摘要	payload 字节变化后,摘要应改变	requests 3→4 后为 5657…d3f6	预测正确

连接错误地址会失败，但不改变本地数据	错误发生在客户端连接阶段	返回 EndpointConnectionError，本地文件仍在	预测正确

五、实验步骤与结果

5.1 身份登记与原始数据生成

```
.\venv\Scripts\python.exe -m coursekit identity --student-id 2410311411 --lab 01 --stage start
.\.venv\Scripts\python.exe -m coursekit seed --rows 20000
```

身份记录 run_id = ac50c736765f4e839f435c83a1de72e4，最终身份记录 run_id = f048eb1f6255478ab5df34cf073e23e5。原始数据生成后行数为 20,102。

5.2 S3 往返与内容哈希

执行 .\.venv\Scripts\python.exe -m coursekit lab01。最终复验 run_id = 34ed93b95c994a1f99563593b5de1f15，结果如下：

字段	实测值
endpoint	http://127.0.0.1:56251
backend	Moto S3 API emulator
bucket	bdp-teaching
key	bronze/events/0d93bcd25e28047f804238c220bdb5b1d2dadf328647c07de85ba0104e8e2854.jsonl
bytes	3,892,184
source SHA-256	0d93bcd25e28047f804238c220bdb5b1d2dadf328647c07de85ba0104e8e2854
download SHA-256	0d93bcd25e28047f804238c220bdb5b1d2dadf328647c07de85ba0104e8e2854
hash_matches	true
version_ids_differ	true

两个摘要完全相同，说明上传和下载后的对象内容逐字节一致。

version_ids_differ=true 说明多次 PUT 产生不同对象版本标识；但版本标识变化不等于内容变化，内容身份仍由摘要说明。



图 2　S3 往返最终结果

5.3 个人对象键改动

```
New-Item -ItemType Directory -Force .\submissions\lab01 | Out-Null
Copy-Item -LiteralPath '.\01. 云端数据接口与可复现环境\附件\student_object_roundtrip.py' -Destination '.\submissions\lab01\student_object_roundtrip.py'
```

基线对象键为 shared/raw/demo.json，运行 run_id = ef597014473f4394a34dd46c9426ba6f，原始与下载摘要均为 23c0b20c65b4476c7e541044c09c88cd970bb02191681f804daef0b7ba49f0e8，equal=true。



图 3　改键前的基线运行

随后只修改 make_key()，把共享前缀改成含本人学号的前缀：

```
-    return "shared/raw/demo.json"
+    return "students/2410311411/raw/demo.json"
```

修改后 run_id = c52a3005f20f4fba87a6eb2c8611fd53，key 为 students/2410311411/raw/demo.json，原始与下载摘要仍为 23c0…f0e8，equal=true。对象键变化后摘要未变化，说明“对象地址”和“内容身份”是两个不同概念；含学号的前缀还能避免不同提交者互相覆盖。



图 4　含本人学号的对象键结果

5.4 payload 数值改动

在改键后的个人副本中，把 payload 的 requests 从 3 改为 4，tokens 保持 120。

```
-               payload    =    json.dumps({"requests":    3,    "tokens":    120},
sort_keys=True).encode("utf-8")
+               payload    =    json.dumps({"requests":    4,    "tokens":    120},
sort_keys=True).encode("utf-8")
```

运行 run_id = 795e796b5fa849a4a83fc5abad552467，key 不变，原始与下载摘要均变为 5657a58e4a955dcf741239aed81c7a600ca434c4b6c738557b8683d12b09d3f6，equal=true。payload 改变后上传与下载仍一致，但摘要改变，说明哈希能够区分不同的内容字节；哈希相等只证明“两端内容相同”，不能证明业务规则正确。



图 5　payload 改动后的运行结果

5.5 故障与恢复

使用无效 endpoint 执行预期失败：

```
.\venv\Scripts\python.exe -m coursekit capture --lab 01 --stage expected-failure -- .\.venv\Scripts\python.exe -m coursekit lab01 --endpoint http://127.0.0.1:1
```

实际返回 EndpointConnectionError: Could not connect to the endpoint URL: "http://127.0.0.1:1/". 故障运行 run_id = 1b1f4b877db64afb9a8c86cf0b27f906，退出码为 1；内部失败运行 run_id = 8f7bab6faab1429c97e961be0278ab37。错误发生在客户端连接阶段，没有证据表明上传成功，也不是数据质量问题。



图 6　无效 endpoint 的预期失败

恢复时重新使用默认本地临时服务，执行 .\.venv\Scripts\python.exe -m coursekit lab01。恢复运行 run_id = b96073ff4f49420d9099575718d77521，最新复验 run_id = 34ed93b95c994a1f99563593b5de1f15，两次均返回 hash_matches=true。这说明修正的是服务地址，而不是改写原始数据或伪造哈希。



图 7　恢复后的成功往返

六、结果汇总

运行	对象键	内容 SHA-256	下载一致	run_id
S3 主数据往返	bronze/events/0d93…2854.jsonl	0d93bcd2…e2854	是	34ed93b9…1f15
个人基线	shared/raw/demo.json	23c0b20c…9f0e8	是	ef597014…ba6f
改对象键	students/2410311411/raw/demo.json	23c0b20c…9f0e8	是	c52a3005…1fd53

改 payload	students/2410311411/raw/demo.json	5657a58e…9d3f6	是	795e796b…52467
无效 endpoint	未进入实际上传	无成功结果	否，连接失败	1b1f4b87…7f906
恢复运行	bronze/events/0d93…2854.jsonl	0d93bcd2…e2854	是	b96073ff…77521

注：为避免表格过宽，摘要列显示首尾片段；完整 SHA-256 已在 5.2—5.4 节和证据 JSON 中列出。

七、模拟与真实云的能力边界

能力	本实验是否验证	说明
本机 HTTP 请求	已验证	通过 127.0.0.1 与 Moto 服务完成 PUT/GET
S3 API 基本往返	已验证	使用 boto3 的 put_object()、get_object()
文件字节一致性	已验证	原始与下载 SHA-256 完全相同
数据业务合法性	未验证	原始数据中仍包含 100 条重复和 2 条非法记录
云端持久性	未验证	Moto 默认保存在内存，服务停止后对象消失
跨机容灾	未验证	所有服务与客户端都在同一台 Windows 电脑
真实 IAM 与访问控制	未验证	使用测试凭据，没有真实账号和权限策略
真实云账单与弹性扩展	未验证	没有调用公有云资源，也没有规模或计费实验

因此，本实验可以证明“本机 S3 API 往返后内容未变”，不能写成“完成了真实云部署”或“证明了生产级耐久性”。

八、分析题

1. 相同数据保存为两个对象键，为什么 SHA-256 不一定改变？因为 SHA-256 计算对象内容的字节序列，不包含桶名和对象键。对象键改变只改变寻址位置，不改变内容字节。

2. JSON 调整空格时，字节一致性和业务含义是否相同？不相同。增加或删除空格通常改

变文件字节和 SHA-256，但如果 JSON 解析后的键值不变，业务含义可能相同。

3. 上传 input_tokens=-1 的文件成功，能证明什么？只能证明传输接口接受了文件字节，上传和下载链路可工作；不能证明字段范围合法、统计规则正确或业务数据可发布。

4. Moto 临时服务停止后，为什么还能做实验 02？因为实验 01 已把原始数据保存在本地 data/raw/events.jsonl，实验 02 直接读取本地文件；Moto 只承担本轮对象接口往返验证。

5. 改用真实云对象存储还要验证什么？还需验证身份认证与授权、桶策略、加密、区域与一致性、耐久性、审计日志、生命周期、配额、网络、故障恢复和真实费用。

九、实验总结与下一章交接

- 建立 Python 3.12.13 课程环境并通过依赖检查；
- 生成默认规模 20,102 行原始事件，记录原始 SHA-256；
- 通过 Moto S3 API 完成上传、下载和双哈希比较；
- 将个人对象键改为 students/2410311411/raw/demo.json，验证键变化不改变内容摘要；
- 将 payload 的 requests 从 3 改为 4，验证内容变化会改变摘要；
- 使用无效 endpoint 取得真实连接失败证据，并在恢复后再次通过往返校验；
- 明确本机模拟服务与真实公有云之间的能力边界。

下一章实验 02 将直接读取 data/raw/events.jsonl，其 SHA-256 为 0d93bcd25e28047f804238c220bdb5b1d2dadf328647c07de85ba0104e8e2854。实验 02 还需要处理本实验尚未解决的 100 条重复记录和 2 条非法记录，不能把“上传成功”误认为“数据质量合格”。

附录：运行证据索引

运行 JSON/HTML 位于 evidence/运行记录/，原始截图位于 evidence/截图/。

阶段	run_id	证据文件
身份开始	ac50c736765f4e839f435c83a1de72e4	ac50c736765f4e839f435c83a1de72e4-start.html

环境检查	8a813bc368a34c959cca8a326e937ab4	8a813bc368a34c959cca8a326e937ab4-environment.html
S3 首次往返	2869cab608d145ddbc9eebe8cd25f612	2869cab608d145ddbc9eebe8cd25f612-verify.html
个人基线	ef597014473f4394a34dd46c9426ba6f	ef597014473f4394a34dd46c9426ba6f-student_object_roundtrip.html
改对象键	c52a3005f20f4fba87a6eb2c8611fd53	c52a3005f20f4fba87a6eb2c8611fd53-student_object_roundtrip.html
改 payload	795e796b5fa849a4a83fc5abad552467	795e796b5fa849a4a83fc5abad552467-student_object_roundtrip.html
预期失败	1b1f4b877db64afb9a8c86cf0b27f906	1b1f4b877db64afb9a8c86cf0b27f906-expected-failure.html
失败内部记录	8f7bab6faab1429c97e961be0278ab37	8f7bab6faab1429c97e961be0278ab37-failed-lab01.html
恢复运行	b96073ff4f49420d9099575718d77521	b96073ff4f49420d9099575718d77521-verify.html
最终复验	34ed93b95c994a1f99563593b5de1f15	34ed93b95c994a1f99563593b5de1f15-verify.html
身份结束	f048eb1f6255478ab5df34cf073e23e5	f048eb1f6255478ab5df34cf073e23e5-final.html

报告正文学号：2410311411