

《云计算与大数据处理》
实验报告

实验名称	实验二　数据湖与质量契约
实验日期	2026 年 10 月 26 日
专业	计算机科学与技术
班级	24 计科 4
学号	2410311411
姓名	何嘉欣
指导教师	刘锦行

实验二　数据湖与质量契约

一、实验目的

本实验把实验一“字节能够保存并往返”的结论推进到“数据可以被可靠分析”。以 20,102 行合成服务事件为输入，建立 Bronze、Silver、Gold 三层：原始层保留全部记录，Silver 按明确契约校验、隔离和去重后写成 Parquet，Gold 用固定 SQL 口径按日期与服务聚合。

实验重点是证明清洗过程的守恒关系，区分非法、重复和同 ID 冲突，理解严格类型校验、UTC 时间、Parquet 行组、列裁剪和谓词下推，并通过个人阈值 2000→1200 的改动说明技术校验与业务政策的边界。

二、实验环境与前置数据

项目	实测值
操作系统	Windows 11
Python	3.12.13
项目解释器	D:\云计算与大数据处理\reference-BDP\.venv\Scripts\python.exe
工作目录	D:\云计算与大数据处理\reference-BDP
DuckDB / PyArrow	1.5.5 / 25.0.1
原始文件	data/raw/events.jsonl
原始规模	20,102 行，3,892,184 字节
原始 SHA-256	0d93bcd25e28047f804238c220bdb5b1d2dadf328647c07de85ba0104e8e2854

原始数据由实验一继承，随机种子为 42；raw.json 记录合法独特 20,000、重复 100、非法 2。实验二的基线运行 run_id 为 e6a3a1ca90d1478688541f770a936ddf，stage 为 verify。清洗前后没有重新生成原始文件。



图 1　实验二基线质量、守恒关系与服务汇总（学号、实验号、run_id 与结果同屏）

三、数据契约与处理规则

字段	契约	拒绝原因示例
event_id	非空字符串，事件主键	invalid_event_id

event_time	可解析的 ISO 时间，且 UTC 偏移必须为 0	invalid_event_time / non_utc_time
service	assistant、search、batch	invalid_category
model	small、medium	invalid_category
input_tokens	严格 int，且大于等于 0	invalid_input_tokens
output_tokens	严格 int，且大于等于 0	invalid_output_tokens
latency_ms	严格 int，且大于等于 0	invalid_latency_ms
status	ok、error	invalid_status

字段先检查是否存在，再检查类型、范围和枚举，最后解析时间。type(x) is int 是严格判断：布尔值虽然继承 int，但不作为 1 Token 接收；数字字符串也不隐式转换，以免掩盖上游接口错误。UTC 时间先解析，再统一规范化为 datetime.isoformat() 后参与去重。

event_id 相同且其余内容完全一致时计为重复；event_id 相同但内容不同时视为冲突并停止发布。不能默认“最后一条正确”，必须先定义更正、版本或纠错事件政策。拒绝记录写入 quarantine，保留原始行号、原因和原值，不静默删除。

四、独立手算：六行小表

到达顺序	event_id	input_tokens	特别说明	处理结果
1	a	10	合法	保留
2	b	20	合法	保留
3	a	10	与第一行完全相同	重复
4	c	-1	非法负数	隔离：invalid_input_tokens
5	d	40	时间为 not-a-time	隔离：invalid_event_time
6	e	30	合法	保留

手算结果：合法独特 3 条（a、b、e），重复 1 条，隔离 2 条，保留事件的 input_tokens 总量为 10+20+30=60。数量守恒为 3+1+2=6。

若第 3 行改为 event_id=a、input_tokens=99，则它与第 1 行 ID 相同而内容不

同，不能再计为普通重复，也不能简单保留最后一条。正确做法是停止发布并依据版本号、更新时间或显式纠错事件确定哪条代表业务事实；本实验的共同数据选择报冲突，避免在规则未定义时静默覆盖。

五、基线质量与隔离结果

指标	实测值	说明
原始条数	20,102	JSONL 总行数
合法独特	20,000	写入 Silver 的主键唯一记录
重复	100	ID 与全部字段完全相同
拒绝	2	进入隔离区并记录原因
守恒	20,102	20000+100+2
输入 Token 总量	18,015,640	仅统计合法独特记录

原始行号	event_id	拒绝原因	原值
20,101	bad-negative	invalid_input_tokens	input_tokens=-1
20,102	bad-time	invalid_event_time	event_time=not-a-time

两条拒绝都不是流水线失败，而是契约按预期隔离坏记录。第一条类型为整数但范围非法；第二条字段存在但无法解析为 ISO 时间。保留原值使“哪一行、为什么拒绝、原值是什么”能够追溯。

service	请求数	输入 Token	输出 Token	延迟总和(ms)	错误请求
assistant	14,008	12,631,850	4,310,029	28,448,309	543
batch	2,023	1,816,567	616,515	4,079,006	78
search	3,969	3,567,223	1,219,318	8,137,035	179

服务汇总的请求数合计为 20,000，输入 Token 合计为 18,015,640，输出 Token 合计为 6,145,862。Gold 统计合法日志中的全部请求，status=error 的 800 条请求仍计入请求数和资源口径；若只对成功请求计费，必须另行定义并解释口径。

六、Parquet 存储与 SQL 聚合

Silver 文件使用 Zstd 压缩，row_group_size=4096。实际写入 20,000 行、5 个行组，schema 含 string 类型的事件与类别字段、int64 类型的三个计数字段。原始 JSONL 为 3,892,184 字节，Silver Parquet 为 224,693 字节，约缩小到原来的 5.8%；但这不是纯格式性能对照，因为 Silver 已去掉坏行和重复，JSONL 是行式文本，Parquet 是列式压缩文件。



图 2　Parquet schema、20,000 行与 5 个行组实测（run_id f6457389…814f53）

查询计划显示 READ_PARQUET 的投影只有 input_tokens，过滤条件为 service='search'，读取 1 个文件和 3,969 行。这说明查询只投影需要的列，并把过滤条件下推到扫描阶段；不能据此宣称已经发生目录分区裁剪。本章只有一个 Parquet 文件，没有按日期或服务建立目录分区；行组是文件内部的水平批次，目录分区是按路径键值拆分数据，两者不是同一概念。

```
SELECT CAST(CAST(event_time AS TIMESTAMP) AS DATE)::VARCHAR AS day, service,
       COUNT(*) AS requests, SUM(input_tokens)::BIGINT, SUM(output_tokens)::BIGINT
FROM events
GROUP BY day, service
ORDER BY day, service;
```

day	service	requests	input_tokens	output_tokens
2026-03-01	assistant	12,142	10,943,399	3,743,595
2026-03-01	batch	1,722	1,542,888	526,892
2026-03-01	search	3,416	3,066,824	1,043,954
2026-03-02	assistant	1,866	1,688,451	566,434
2026-03-02	batch	301	273,679	89,623
2026-03-02	search	553	500,399	175,364



图 3　Silver 与 Gold 请求数和 Token 总量守恒（run_id 032c60ce…5b2af）

核对结果为 silver_totals=(20000, 18015640, 6145862)，gold_totals=(20000, 18015640, 6145862)，totals_match=true。分组粒度不同但总量一致，说明聚合没有无故丢账。

七、个人改动：输入 Token 上限 2000→1200

修改前先预测：课程合法数据的 input_tokens 最大不超过 1800，因此 2000 上限不会拒绝任何已合法事件；把上限改为 1200 后，超过 1200 的合法请求会被附加业务政策拒绝，合法独特数和输入 Token 总量都应下降。由于脚本先校验再去重，原本可计入重复的高 Token 行也会先进入拒绝计数，因此重复数可能从 100 降到更低。

- MAX_INPUT_TOKENS = 2000

MAX_INPUT_TOKENS = 1200

规则	原始条数	合法独特	重复	拒绝	输入 Token 总量
基础课程契约	20,102	20,000	100	2	18,015,640
附加上限 2000	20,102	20,000	100	2	18,015,640
附加上限 1200	20,102	13,405	67	6,630	8,110,488

1200 规则的拒绝构成为 policy_input_limit=6,628、invalid_input_tokens=1、invalid_event_time=1；守恒为 13,405+67+6,630=20,102。与 2000 相比，合法独特减少 6,595 条，重复减少 33 条，说明有 33 条重复记录也因超过阈值而先被拒绝。输入 Token 总量减少 9,905,152，约占原来的 55.0%。

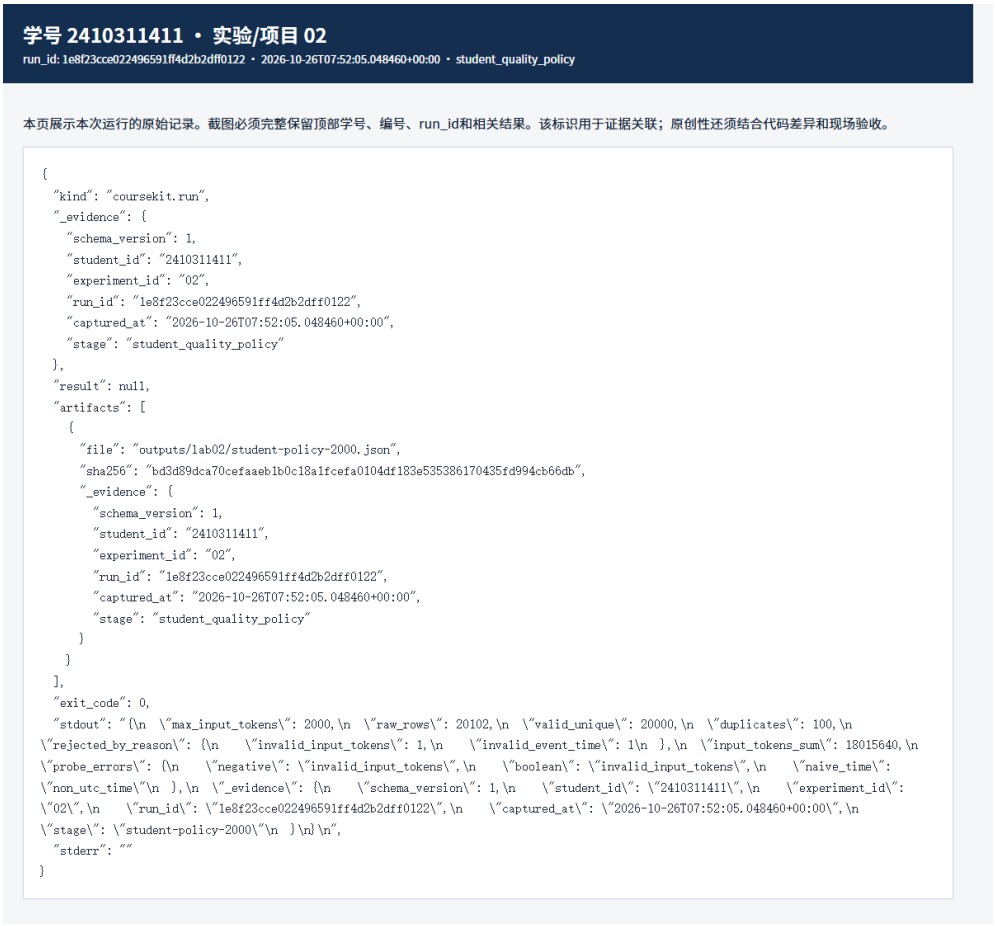


图 4　个人政策 2000 上限：20,000 条合法独特，拒绝仅来自两类坏记录

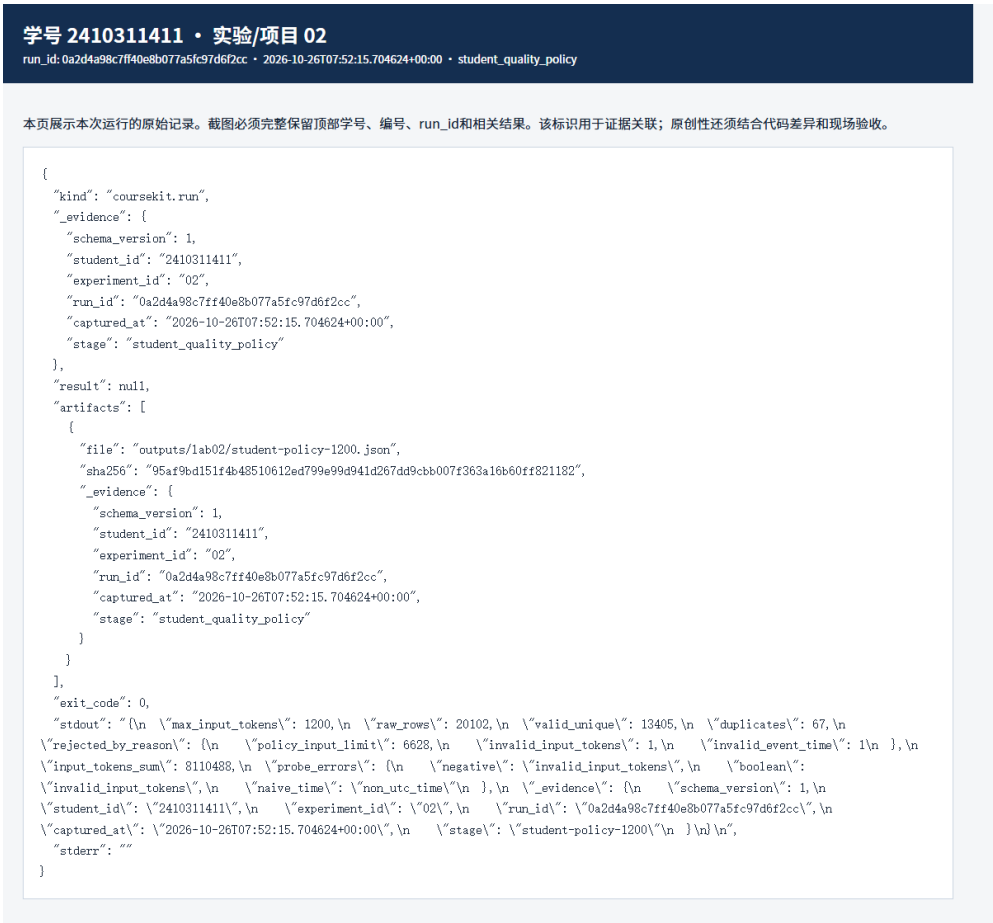


图 5　个人政策 1200 上限：13,405 条合法独特，6,628 条因业务上限被拒绝

技术校验回答“记录是否合法”，业务政策回答“某类合法请求是否属于本次分析范围”。1200 上限不会把负数或坏时间变合法，也不会修复重复，它只是把“技术上合法但输入量高于业务阈值”的请求排除。该阈值适合成本控制或小请求分析，但会丢失大请求，不能直接替代课程共同契约，也不能覆盖实验三、四使用的 Silver。

八、契约探针、预期失败与恢复

探针	输入	实测结果	解释
布尔值	True	invalid_input_tokens	bool 是 int 子类，但契约要求精确 int
数字字符串	100	invalid_input_tokens	不做隐式字符串转整数
整数	100	accepted	类型和范围均符合契约
负数	-1	invalid_input_tokens	范围小于 0
无时区时间	2026-03-01T12:00:00	non_utc_time	缺少 UTC 偏移

布尔值和字符串都得到 invalid_input_tokens，但原因不同：True 的问题在于类型不是精确 int，即使它可被 Python 当作整数参与运算；100 的问题在于值是字符串，必须由上游明确修正类型或定义转换规则。二者若被静默接受，都会掩盖接口契约错误。



图 6　布尔值、数字字符串、整数、负数与无时区时间的契约探针（run_id 5be251e8…b99ea7）

预期失败运行时，把 100 假定为可接受输入，实际返回 exit_code=1、reason=invalid_input_tokens，stderr 为 EXPECTED_ACCEPT_BUT_GOT_invalid_input_tokens。恢复时把样本改成整数 100，运行返回 exit_code=0、reason=accepted。修复的是测试样本的类型，不是放宽全局校验。



图 7　数字字符串被拒绝的预期失败（run_id b54b88af…04151b）



图 8　改为整数 100 后的恢复结果（run_id 16e746cf…15e39）

九、文件血缘与哈希核验

清单字段	实测值
source_sha256	0d93bcd25e28047f804238c220bdb5b1d2dadf328647c07de85ba0104e8e2854
silver_sha256	516b3d78aab91c1487d9a24979eaef514c5acb7309d0d82a6688a762836634dc
gold_sha256	654e0aeb835565d09b61f965015b61c3442c78e3cc320ca6e1e25b94e02dfc6e
rows / contract_version	20,000 / 2

时间政策	解析 UTC ISO 时间并规范化为 datetime.isoformat()



图 9　原始、Silver、Gold 三个摘要与清单一致（run_id ac8b59db…5fb408）

后续消费者先读取 silver.json，逐个重算原始文件、Silver 和 Gold 的 SHA-256，再决定是否继续计算。若原始文件变化，必须重新完成实验一往返并重跑实验二；若仅 Silver 或 Gold 损坏，则重跑实验二。不能直接改清单摘要让检查变绿。

文件清单提供内容核验和最小血缘，但不是 ACID 事务，也不是完整湖仓表格式：它没有事务日志、并发提交、快照隔离、时间旅行或多文件原子提交能力。

十、必答分析题

1. True、"100" 与整数 100 的处理不同：契约要求 input_tokens 的类型精确为 int。True 虽可被 isinstance(True, int) 识别为整数子类，但不是业务整数；"100" 是字符串，需要上游显式修正类型。只有整数 100 同时满足类型与范围。

2. 同 ID 内容冲突不能当作普通重复，因为两条记录对同一业务对象给出了不同事实。直接保留任意一条都会掩盖更正语义；应先定义版本、更新时间或纠错事件政策，再决定发布哪条。

3. 原始 JSONL 与 Silver Parquet 的大小比较不是纯格式性能对照：输入还包含 100 条重复和 2 条坏记录，Silver 已清洗；JSONL 是行式文本，Parquet 采用列式编码和 Zstd 压缩。大小差异同时来自数据范围、编码和压缩。

4. 列裁剪是只读取查询需要的列；谓词下推是把过滤条件交给底层扫描；行组是 Parquet 文件内部的一批行及其统计信息；目录分区是按日期、服务等键值拆成不同路径。本章实现了列裁剪、扫描过滤和 5 个行组，但没有实现目录分区，也不能证明所有行组都被跳过。

5. 阈值 1200 会丢掉输入量大于 1200 的合法业务请求，本次减少 6,595 条合法独特记录和约 55.0% 的输入 Token。技术校验判断字段是否合法；业务政策判断合法请求是否属于当前分析范围。前者不能放宽，后者必须由业务目标和代价共同决定。

6. 清单只保存文件摘要、行数、schema 和契约版本，能发现内容变化，但不能提供事务提交、并发控制、快照隔离或时间旅行。它适合作为最小血缘与完整性核验，不等于 ACID 数据库或完整湖仓表格式。

十一、结论与局限

实验完成了从原始 JSONL 到 Silver Parquet 再到 Gold 日汇总的可复现链路。基线 20,102 条记录全部有去向：20,000 条合法独特、100 条重复、2 条隔离，数量和 Token 总量均守恒；Gold 与 Silver 的请求数及 Token 总量一致。个人 1200 阈值进一步说明，合法数据也可能因业务范围被排除，必须把误拒绝代价写清楚。

本实验仍有边界：所有计算在单机 CPU 完成，去重使用内存字典，数据规模约 2 万行；只有一个 Parquet 文件，没有目录分区和跨机容灾；清单不是事务系统；Gold 统计包含错误请求，只代表当前资源口径。更大规模需要外部排序、分布式去重、分区治理和并发提交机制。

十二、运行证据索引

运行 JSON 与同名 HTML 位于 evidence/运行记录/，原始截图位于 evidence/截图/。本报告引用的运行如下。

阶段	run_id	对应截图

基线质量	e6a3a1ca90d1478688541f770a936ddf	01-baseline-quality.png
Gold 总量	032c60ce145e4b5bac22eec26fa5b2af	02-gold-totals.png
Parquet 行组	f645738912114475b6f351408c814f53	03-parquet-rowgroups.png
清单哈希	ac8b59db03da425c87bfc8ddb65fb408	04-manifest-hash.png
政策 2000	1e8f23cce022496591ff4d2b2dff0122	05-policy-2000.png
政策 1200	0a2d4a98c7ff40e8b077a5fc97d6f2cc	06-policy-1200.png
契约探针	5be251e845014e62bee30e5dbbb99ea7	07-contract-probes.png
预期失败	b54b88afad3b495f8310601935a4151b	08-expected-failure.png
恢复运行	16e746cfe24e4a5f95a6eaf282c15e39	09-recovered.png

十三、代码仓库

实验一与实验二的报告、代码、运行记录和截图已汇总到以下仓库：

https://github.com/wxzn222/cloud_computing_and_bigdata_processing

报告正文学号：2410311411　　实验/项目号：02